

תסריט מעודכן להצגת הפוסטר - Prediction Rootzone

1. פתיחה, רקע ומוטיבציה:

שלום, אנחנו ועדן ואורן והפרויקט שלנו עוסק בחיזוי משתנים בסביבת בית השורשים של צמחים בחממה.

אז לפני שנכנסים לפרויקט עצמו, חשוב להבין מה זה בכלל Rootzone. אז Rootzone הוא אזור בית השורשים - הסביבה שבה השורשים נמצאים וקולטים מים, דשן ומינרלים. בחממות מודרניות, במיוחד בגידול במצע מנותק, האזור הזה רגיש מאוד, ואם התנאים בו יוצאים מאיזון, הצמח יכול להיפגע גם אם מעל פני הקרקע הכל נראה תקין.

בפרויקט שלנו התמקדנו בחיזוי שניים מהמשתנים החשובים ביותר בבית השורשים: EC ו-pH.

EC, כלומר מוליכות חשמל, הוא מדד המייצג את כמות המלחים המומסים בתמיסה סביב השורשים. הוא נותן לנו אינדיקציה לריכוז הדשן והמלחים שהצמח פוגש בפועל. אם EC נמוך מדי, זה יכול להעיד על חוסר הזנה או על תמיסה מדוללת מדי. אם EC גבוה מדי, זה יכול להעיד על הצטברות מלחים ועל מצב שבו לצמח קשה יותר לקלוט מים.

pH הוא מדד לחומציות של התמיסה סביב השורשים. הוא חשוב כי הוא משפיע על זמינות יסודות ההזנה לצמח. pH מחוץ לטווח האופטימלי יכול לגרום לכך שחלק מהיסודות יהיו פחות זמינים, ולכן הצמח לא באמת יוכל לנצל את כל ההזנה שקיבל.

הבעיה המעשית היא שברוב החממות כן מבצעים מדידות מדויקות של pH ו-EC, אבל המדידות האלה נעשות בתדירות נמוכה יחסית. לכן רוב הזמן אנחנו לא יודעים מה המצב האמיתי של בית השורשים, אלא רק מה היה המצב בנקודות הדגימה האחרונות. בין שתי מדידות יכולים להתרחש שינויים משמעותיים בגלל דישון, השקיה ושינויי מזג אוויר. אם השינויים האלה יוצרים חריגה מהטווח האופטימלי, נגלה את זה רק כפעם הבאה שנדגום. ואז נצטרך לבצע פעולה מתקנת אחרי שהבעיה כבר הופיעה.

אנחנו לא רוצים להגיע למצב הזה. הרעיון שלנו הוא לבנות חיישן תוכנה המאפשר לחזות, על סמך הנתונים שכבר זמינים בחממה, מה צפוי להיות מצב בית השורשים. כך אפשר להתאים מראש את תוכניות הדישון והשקיה לפי מזג האוויר, מצב הצמח והמדידה האחרונה, ולוודא שאנחנו נשארים בטווח האופטימלי.

2. מטרת הפרויקט, התוצר והערך היישומי:

המטרה שלנו הייתה לבנות soft sensor לבית השורשים. כלומר לא חיישן פיזי שמודד ישירות, אלא מודל שמעריך את pH ו-EC מתוך נתונים אחרים שידועים לנו כמו: אקלים, השקיה, דישון, מצב הצמח, והמדידה הידנית האחרונה.

התוצר שאליו כיוונו הוא מערכת תומכת החלטה: המגדל מזין או מעלה את תמונת המצב הנוכחית, כולל pH ו-EC אחרונים, נתוני אקלים, מצב הצמח ותכנון השקיה ודישון העדכני; והמערכת מחזירה תחזית לערכי pH ו-EC בזמן יעד עתידי.

הערך היישומי הוא מעבר מניהול תגובתי לניהול פרואקטיבי: אם המודל מזהה שתרחיש השקיה או דישון צפוי להוביל ל-pH או EC בעייתיים, אפשר לשנות את התוכנית לפני שהבעיה מופיעה במדידה הידנית הבאה.

3. הדאטה: מקורות, סדר גודל והכנה:

בנינו בסיס נתונים אחיד ברזולוציה של 10 דקות. בגרסה הסופית יש 16,682 רשומות, עם מעל 20 עמודות, מטווח התאריכים 29 במאי עד 21 בספטמבר 2025.

הנתונים הגיעו מכמה קבוצות:

- נתוני מזג אוויר חיצוניים וקרינה - תחנת מזג אוויר וקובצי radiation חיצוניים. אלו נותנים לנו את התנאים שמניעים את החממה מבחוץ.
- נתוני מיקרו-אקלים בתוך החממה - טמפרטורה פנימית, לחות, קרינה פנימית, ET0 וטמפרטורת קרקע או הערכה שלה. אלו מייצגים את הסביבה שהצמח באמת חווה.
- נתוני ממשק גידול - השקיה, דישון, סוגי דשן, חומצה, מלחים, גבס ו-Kortin. אלו הפעולות שהמגדל מבצע, והן משפיעות ישירות על בית השורשים.
- נתוני מצב צמח - כיסוי נוף וגיל הצמח. אלו חשובים כי צמח צעיר וצמח מפותח לא צורכים מים ודשן באותו אופן.
- מדידות ידניות של pH ו-EC - אלו תוויות האמת של המודל Rootzone.

האתגר המרכזי הוא שהנתונים צפופים מאוד בצד האקלימי והתפעולי, אבל תוויות pH ו-EC דלילות מאוד: יש רק 109 מדידות ידניות. כלומר, יש לנו הרבה מידע שיכול להסביר את התהליך, אבל מעט נקודות אמת שבהן אנחנו יודעים בוודאות מה היה מצב בית השורשים. העבודה על הדאטה כללה: יישור timestamps מכל הקבצים. המרה לפורמט זמן אחיד של 10 דקות. איחוד עמודות שהגיעו בשמות ובפורמטים שונים. חישוב משתנים חסרים או נגזרים, למשל ET0 או טמפרטורת קרקע. סיכום אירועי השקיה ודישון לחלונות זמן. חיבור מדידות pH ו-EC לנקודות עוגן ולנקודות יעד.

4. ארכיטקטורה ושיטה: למה שני שלבים ואיך מתכננים את החיזוי

תכננו את המערכת כ-pipeline דו-שלבי. הסיבה לפיצול היא שבזמן חיזוי עתידי יש לנו שתי בעיות שונות:

1. קודם צריך לדעת מה יהיו תנאי החממה הפנימיים בעתיד.

2. אחר כך צריך להשתמש בתנאים האלה כדי לחזות את השינוי ב-pH וב-EC.

אם היינו בונים מודל אחד שמקבל רק נתוני עבר, הוא היה נשאר בעיקר תרגיל offline. אבל המטרה היא לאפשר תחזית. לכן השלב הראשון הוא Micro-climate prediction

שלב 1 - Micro-climate prediction

השלב הזה מקבל נתוני מזג אוויר וקרינה חיצוניים, ומייצר את משתני האקלים הפנימיים שהמודל השני צריך: טמפרטורה פנימית, ET0, קרינה פנימית וטמפרטורת קרקע. המטרה שלו היא לגשר בין מה שזמין לתחזית מבחוץ לבין מה שהצמח חווה בתוך החממה. זה חשוב במיוחד כי נתונים פנימיים עתידיים לא תמיד זמינים בזמן אמת.

שלב 2 - Root-zone prediction

בשלב השני הפכנו את הבעיה ל-prediction Interval. כל דוגמה במודל היא לא שורה אחת רגילה, אלא מרווח זמן: t_0 - זמן שבו יש מדידת pH ו-EC ידועה. t_1 - זמן עתידי שאליו רוצים לחזות.

המודל לא שואל "מה הערך עכשיו?" אלא "מה קרה בין t_0 ל- t_1 שיכול להסביר שינוי בבית השורשים?" חשוב להבין שגם במודל בית השורשים אנחנו לא חוזים ערך מנותק מהקשר. אנחנו חוזים שינוי מ- t_0 ל- t_1 , כי לבית השורשים יש זיכרון. הערך האחרון שנמדד הוא נקודת התחלה משמעותית, והפעולות מאז הן אלו שמסבירות את הדינמיקה.

איך הארכיטקטורה עובדת בפועל מבחינת העבודה ההנדסית, בנינו את המערכת כשרשרת מודולרית: קודם שכבת נתונים שמייצרת dataset master אחיד, אחר כך מודל שמייצר את תנאי החממה הפנימיים, ורק לאחר מכן מודל zone-Root שמקבל את תמונת המצב המלאה ומחזיר תחזית pH ו-EC.

מבחינת זרימת החיזוי, המשתמש מתחיל מנתונים זמינים: radiation, weather, מדידת EC/pH אחרונה ותוכנית ממשק. השלב הראשון מתרגם radiation/weather לתחזית תנאים פנימיים. השלב השני מתרגם את המצב ההתחלתי והתרחיש המתוכנן לשינוי צפוי בבית השורשים. לכן הארכיטקטורה לא בנויה כמודל אחד גדול שמנסה ללמוד הכול יחד, אלא כמערכת שבה כל שלב מייצג חלק אמיתי בתהליך החקלאי: קודם הסביבה, אחר כך תגובת בית השורשים. מכאן עברנו לשאלה איזה אלגוריתם מתאים לדאטה כזה.

5. אלגוריתמים ושיטות:

המודל הסופי הוא model Unified שחזה גם pH וגם EC מאותו set of features.

במקום שני pipelines נפרדים לגמרי, רצינו להשתמש באותו תיאור של המצב החקלאי והאקלימי כדי ללמוד את שתי התגובות. האלגוריתם המרכזי הוא XGBoost. בחרנו בו כי זו בעיית דאטה טבלאי, עם מספר תוויות לא גדול, והרבה אינטראקציות לא לינאריות: אקלים משפיע אחרת לפי מצב הצמח. דישון משפיע אחרת לפי כמות השקיה. שינוי EC תלוי גם ב-EC ההתחלתי. אותו אירוע יכול להשפיע אחרת לפי הזמן שעבר מאז שהוא התרחש.

Learning Deep לא היה מתאים כאן כבחירה ראשית, כי יש רק 109 תוויות pH ו-EC. מודל עמוק היה עלול ללמוד רעש או לזכור את הדאטה במקום ללמוד תהליך.

בנוסף השתמשנו במודל היברידי: XGBoost כמודל המרכזי, ורכיב linear robust / Huber למצבים חריגים ומוגדרים מראש. הסיבה היא ההבדל בין אינטרפולציה לאקסטרפולציה. מודלים מבוססי עצים, כמו XGBoost, חזקים מאוד באינטרפולציה - כלומר כאשר הדוגמה החדשה דומה לאזורים שכבר ראינו בדאטה. הם יודעים לחלק את מרחב הפיצ'רים לאזורים וללמוד דפוסים לא לינאריים מורכבים. אבל כאשר מגיע תרחיש קיצוני או נדיר, למשל קפיצת מלחים אחרי דישון או שינוי חד ב-EC, מודל עצים לא באמת ממשיך קו מעבר למה שראה; הוא נוטה

להחזיר ערך לפי העלים והדוגמאות הדומות ביותר. לכן הוספנו רכיב linear robust שמבוסס על Huber. הוא פשוט יותר, אבל מתאים יותר למצבים שבהם רוצים תגובה יציבה למגמה חריגה בלי להיות רגישים מדי ל-outliers. הוא לא מחליף את XGBoost בכל התחזיות. בפועל, ברירת המחדל היא XGBoost. הרכיב ה-Robust מופעל רק כאשר תנאי gate מזהים תרחיש כימי רגיש: למשל כמות מלחים/דישון גבוהה, מעט השקיה אחרי אירוע מלח, ריכוז מלח גבוה, EC התחלתי נמוך יחסית, ופער זמן קצר יחסית. כלומר, רוב התחזיות הן אינטרפולציה לא לינארית של XGBoost, ובמצבי shock מוגדרים אנחנו עוברים לרכיב היציב יותר כדי להתמודד טוב יותר עם תרחישים שנמצאים בקצה ההתפלגות. עבור EC השתמשנו ב-logic change-log, כי EC הוא ערך חיובי, והיחס בין שינוי קטן לשינוי גדול חשוב יותר מערך מוחלט בלבד. זה עוזר למודל להתייחס לשינויי מליחות בצורה יציבה יותר.

6. שיטת ולידצית walk-forward עבור המודלים:

בפריקט כזה קל מאוד לקבל תוצאה טובה בצורה לא הוגנת אם משתמשים בטעות במידע מהעתיד. לכן שמנו דגש על validation שמדמה deployment. במודל המיקרו-אקלים השתמשנו ב-forward-Walk. התחלנו מכמות התחלתית של דאטה היסטורי, אימנו את המודל על התקופה הזו, ואז בכל איטרציה ביקשנו ממנו לחזות 3 ימים קדימה מתוך נתוני האקלים החיצוני והקרינה בלבד. לאחר שהתקופה של 3 הימים הסתיימה, השוונו בין התחזית לבין הערכים האמיתיים שנמדדו בתוך החממה. רק לאחר מכן הוספנו את אותם 3 ימים לסט האימון והמשכנו לחלון הבא. בצורה הזו בדקנו האם המודל באמת מסוגל לחזות קדימה, ולא רק להתאים את עצמו לדאטה שכבר ראה. זה חשוב כי המיקרו-אקלים הוא השלב שמזין את מודל בית השורשים. אם השלב הראשון לא אמין, גם השלב השני יקבל קלט בעייתי. במודל Rootzone השתמשנו גם ב-forward-Walk, אבל כאן יחידת הבדיקה היא מדידת EC/pH ולא רצף של 3 ימים. forward-Walk עובד כמו סימולציה של שימוש אמיתי לאורך זמן. מתחילים מאוסף מדידות עבר ראשוני. בכל צעד מאמנים את המודל רק על מדידות שכבר קרו, ואז מבקשים ממנו לחזות את המדידה הבאה או אינטרוול עתידי t-0 ל t-1. רק אחרי שהגענו בזמן למדידה הזו, והיא כבר לא עתידית, מותר להוסיף אותה לסט האימון. כך אנחנו מונעים leakage Data: אין מצב שבו המודל רואה מדידת EC/pH עתידית בזמן שהוא אמור לחזות אותה. הבסיס להשוואה היה baseline value-Last: להניח שהערך האחרון שנמדד נשאר נכון. זה baseline חשוב כי הוא מייצג את מה שאפשר לעשות בלי מודל. אם המודל לא מנצח אותו, אין הצדקה מעשית לכל המערכת.

7. תוצאות מודל מיקרו אקלים:

בשלב המיקרו-אקלים קיבלנו תוצאות טובות עבור המשתנים הפנימיים המרכזיים: טמפרטורה פנימית: MAE בערך 0.43 מעלות, R2 בערך 0.97. ET0: בערך MAE 0.0035, R2 0.97 קרינה פנימית: MAE בערך 22.5 m/W, R2 בערך 0.97 טמפרטורת קרקע: MAE בערך 0.86 מעלות, R2 בערך 0.92. לחות פנימית: MAE בערך 3% R2 של 0.86 המשמעות היא שהשלב הראשון הצליח לייצר קלט פנימי טוב למודל בית השורשים, במקום להסתמך רק על מדידות פנימיות עתידיות שלא תמיד קיימות.

8. תוצאות מודל בית השורשים:

עבור PH קיבלנו MAE של 0.33 ו R2 של 0.93. עם שיפור של 62% לעומת Last-value baseline. עבור EC קיבלנו MAE של 0.13 ו R2 של 0.98. עם שיפור של 35% לעומת Last-value baseline. איך מפרשים את זה? MAE אומר בכמה יחידות בממוצע טעינו. עבור pH וז טעות ביחידות pH. עבור EC וז טעות ב-cm/mS. בנוסף אומר לנו R2 כמה מהשונות המודל מצליח להסביר. אבל בגלל שהדאטה קטן, אנחנו לא מסתמכים רק על R2. לכן ההשוואה ל-baseline חשובה מאוד.

9. מסקנות:

המסקנה המרכזית היא שאפשר לבנות Sensor Soft שימושי לבית השורשים גם כאשר מדידות pH ו-EC דלילות, בתנאי שמשלבים אותן עם דאטה תפעולי ואקלימי צפוף.

ההישגים המרכזיים:

1. בנינו בסיס נתונים אחיד ממקורות שונים.

2. בנינו שכבת מיקרו אקלים שמאפשרת להשתמש במודל גם כתחזית.

3. בנינו מודל בית שורשים שמבא pH ו-EC קדימה ומשפר את הדיוק מול baseline

4. בנינו דשבורד שמתרגם את המודל ל-workflow שימושי.

5. ביצענו validation שמדמה שימוש אמיתי ומצמצם סיכון ל-leakage Data.

חשוב להדגיש: לא ניסינו להחליף את המגדל ולא לבנות מערכת בקרה אוטונומית. המטרה היא Support Decision - כלי שנותן תחזית ותובנה, והמגדל נשאר מקבל ההחלטות. הצעד הבא בתהליך הוא לא רק לחזות מה יקרה, אלא להמליץ מה לעשות. כיום צוותים נוספים מהמכון הוולקני מתמקדים בכיוון של מערכת אופטימיזציה: מערכת שתשתמש במודל בית השורשים שלנו כדי להמליץ כמה מים ודשן לתת ומתי, כך שהתחזית תהפוך לכלי תכנון פעולות. כלומר, המודל שלנו יכול להיות שכבת החיזוי שעליה בנויה שכבת החלטה.

10. מגבלות ואתגרים:

האתגר הראשון היה דלילות התוויות. יש הרבה נתוני חיישנים ותפעול, אבל רק 109 מדידות pH ו-EC. התמודדנו עם זה באמצעות ניסוח של בעיית feature engineering, interval predication והשוואה ל baseline.

האתגר השני היה סנכרון מקורות מידע. כל מקור הגיע בפורמט ובתדירות אחרת. התמודדנו עם זה באמצעות dataset master אחיד של 10 דקות.

האתגר השלישי היה חיזוי EC. EC רגיש מאוד לאירועי השקיה, דישון ומלחים, ובערכים נמוכים גם שינוי קטן יכול להיות משמעותי יחסית. לכן השתמשנו ב-change-log ובפיצ'רים שמייצגים הצטברות מלחים והיסטוריה. האתגר הרביעי היה להימנע מ-leakage Data. בגלל שהדאטה הוא סדרת זמן, split רגיל יכול להטעות. לכן השתמשנו ב-forward-Walk validation.

המגבלות: המודל נבדק על עונה אחת וחממה אחת. מספר תוויות pH ו-EC עדיין קטן. צריך לבדוק Generalization על עוד חממות, עונות וגידולים. הדשבורד הוא prototype תומך החלטה ולא מערכת Production מלאה